



Sistema inteligente para el análisis de la voz del cliente en reseñas de productos

Proyecto de Procesamiento de Lenguaje Natural

Análisis de Sentimientos

Jennifer Suarez Gutiérrez | Maestría en Ciencia de Datos e IA

Universidad Católica Boliviana San Pablo · Julio 2026

Estructura de la presentación

1

Problema y caso de uso

¿Qué se resuelve y para quién?

2

Datos y preparación

Origen, tamaño y etiquetado del dataset

3

Pipeline de PLN

Preprocesamiento → Representación → Temas → Sentimiento

4

Comparación de modelos y demostración

Clásico vs. neuronal + Demo en vivo de la interfaz

5

Desafíos, conclusiones y mejoras

Decisiones tomadas, limitaciones y trabajo futuro



Voz del Cliente

Análisis inteligente de reseñas
con Procesamiento de Lenguaje Natural

El problema: ¿qué se resuelve y para quién?



El desafío

El **e-commerce** genera miles de reseñas que las empresas **no pueden analizar manualmente**.

Se pierde información sobre calidad, envío y precio.



La solución propuesta

Una aplicación de **PLN** que integra en una única herramienta:

- Clasificación de **sentimientos**
- Detección de **aspectos** relevantes
- Modelado de **temas** con LDA

¿Para quién es esta solución?



E-commerce



Fabricantes



Atención al cliente



Equipos de marketing



Toma de decisiones basada en datos

Objetivo: Analizar automáticamente reseñas en español para identificar sentimiento, aspectos y tema predominante

Los datos: origen, tamaño y preparación



Origen del dataset

KRadim/edit_amazon_reviews_multi_es

Disponible en [Hugging Face](#)

~**210,000** reseñas en español



Variables incluidas

- Texto completo de la reseña
- Título de la reseña
- Categoría del producto
- Calificación (1-5 estrellas)

Transformación a clasificación multiclase

1-2 ★

Negativo

3 ★


Neutro

4-5 ★

Positivo

- ✓ Sin valores faltantes en variables de análisis
- ✓ Mínimas reseñas duplicadas — proporción insignificante
- ✓ Distribución balanceada entre las tres clases de sentimiento

Pipeline de PLN paso a paso



Preprocesamiento del texto

1. Conversión a **minúsculas**
2. Eliminación de **caracteres especiales**
3. Eliminación de **signos de puntuación**
4. Eliminación de **números**
5. Eliminación de **palabras vacías** (stopwords)

Conservando términos relevantes para el análisis de sentimiento

Técnicas de representación

- **Bag of Words** — Representación básica
- **TF-IDF** — Para Naive Bayes
- **Word2Vec** — Embeddings distribucionales
- **Tokenizer + Embedding** — Para LSTM

Comparación de modelos: clásico vs. neuronal

Modelo	Accuracy	Precision (macro)	Recall (macro)	F1-Score (macro)
LSTM	0,694	0,691	0,694	0,692
Naive Bayes	0,685	0,688	0,685	0,686



Análisis de resultados

- La **LSTM** alcanzó el mejor desempeño
- Diferencia vs NB: **~1 punto %**
- La LSTM captura mejor el **contexto**
- NB sigue siendo **competitivo** con TF-IDF



6 Temas identificados (LDA)

- **Funcionamiento**
- **Envío** y logística
- **Calidad-precio**
- **Diseño** y estética
- **Accesorios** y facilidad de uso

Conclusión: La LSTM ofrece mejor capacidad para comprender el contexto del lenguaje, aunque NB sigue siendo una alternativa viable

★ LO MÁS IMPORTANTE ★

Demostración en vivo del sistema

Interfaz interactiva desarrollada con Gradio



Sentimiento

Pos / Neu / Neg



Probabilidades

De clasificación por clase



Tema principal

Identificado por LDA



Aspectos detectados

En la reseña



<https://b3fe96af8cce1a1eb0.gradio.live/>



Tip: Probar con reseñas positivas, neutras y negativas, incluyendo casos difíciles con ironía o negación

Desafíos encontrados y decisiones tomadas

Selección del conjunto de datos

Disponibilidad limitada de datasets de reseñas en español.

→ **Decisión:** Se seleccionó el dataset **Amazon Reviews en español** disponible en Hugging Face.

Interpretación de los temas generados por LDA

Los temas incluían palabras **muy frecuentes**, pero **poco informativas**.

→ **Decisión:** Se incorporaron **stopwords personalizadas** para obtener temas más interpretables.

Selección del modelo neuronal

Se evaluó la elección entre arquitecturas recurrentes (**GRU** y **LSTM**).

→ **Decisión:** Se seleccionó **LSTM** por su amplio uso y buen desempeño en análisis de sentimientos.

Sobreajuste durante el entrenamiento de la LSTM

El modelo mejoraba en entrenamiento, pero empeoraba en validación (**overfitting**).

→ **Decisión:** Se implementaron **EarlyStopping** y **ReduceLROnPlateau** para detener el entrenamiento en la mejor época y mejorar la capacidad de generalización.

Conclusiones, limitaciones y mejoras futuras



Conclusiones

- Solución **completa de PLN** para voz del cliente
- La **LSTM** alcanzó el mejor desempeño pero la diferencia con NB fue **pequeña**.
- NB sigue siendo **competitive**.



Limitaciones

- Precisión moderada (~**69%**).
- Dependencia del **vocabulario de entrenamiento**.
- Dificultad con **ironía** y expresiones complejas.
- Dominio específico (reseñas de productos)



Trabajo futuro y mejoras

- Evaluar **BETO** (Transformers para español)
- Comparar rendimiento con arquitecturas **GRU**
- Incorporar técnicas **supervisadas** para detección de aspectos
- **Desplegar** la aplicación en la nube
- Expandir a **más categorías** de productos
- Mejorar manejo de **negación e ironía**

¡Gracias!

Jennifer Suarez Gutiérrez

Maestría en Ciencia de Datos e IA

Universidad Católica Boliviana San Pablo

[Demo en vivo →](#)

Santa Cruz de la Sierra, Bolivia · Julio 2026