

UNIVERSIDAD CATÓLICA BOLIVIANA SAN PABLO



MAESTRÍA EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

PROYECTO:

**Sistema inteligente para el análisis de la voz del cliente en reseñas de
productos**

MÓDULO PROCESAMIENTO DE LENGUAJE NATURAL

Autora: Jennifer Suarez Gutiérrez

Santa Cruz de la Sierra – Bolivia

13 de julio del 2026

1. Introducción

El crecimiento del comercio electrónico ha incrementado significativamente la generación de información en forma de reseñas y opiniones publicadas por los consumidores sobre los productos que adquieren. Estas reseñas representan una valiosa fuente de información para las empresas, ya que permiten conocer la percepción de los clientes respecto a diferentes características de los productos y servicios. Sin embargo, debido al gran volumen de comentarios generados diariamente, su análisis manual resulta poco práctico y demanda herramientas que permitan procesar esta información de manera automática.

En este contexto, el Procesamiento del Lenguaje Natural (PLN) se ha consolidado como una de las principales áreas de la inteligencia artificial para el análisis de información textual. Mediante técnicas de representación del texto, clasificación de sentimientos, modelado de temas y aprendizaje profundo, es posible extraer conocimiento relevante a partir de grandes volúmenes de opiniones, facilitando la toma de decisiones basada en datos y el análisis de la experiencia del cliente.

El presente proyecto desarrolla una aplicación para el análisis de la voz del cliente utilizando reseñas de productos escritas en español. Para ello, se implementa un pipeline completo de Procesamiento del Lenguaje Natural que integra exploración de datos, preprocesamiento, representación del texto, modelado de temas mediante LDA, clasificación de sentimientos utilizando Naive Bayes y LSTM, detección de aspectos e implementación de una interfaz interactiva con Gradio, permitiendo analizar automáticamente nuevas reseñas de productos.

2. Definición del problema

El crecimiento del comercio electrónico ha provocado un incremento considerable en la cantidad de reseñas que los clientes publican sobre los productos adquiridos. Estas opiniones contienen información valiosa sobre la experiencia del consumidor, incluyendo aspectos relacionados con la calidad del producto, el funcionamiento, el precio, la entrega y la satisfacción general. Sin embargo, cuando una empresa comercializa

cientos o miles de productos y recibe un gran volumen de comentarios diariamente, resulta inviable analizar manualmente cada una de estas reseñas.

Como consecuencia, muchas organizaciones desaprovechan información que podría utilizarse para mejorar sus productos, optimizar procesos logísticos, identificar problemas recurrentes y comprender las necesidades reales de sus clientes. Además, una simple clasificación entre opiniones positivas y negativas no proporciona suficiente información para la toma de decisiones, ya que también es importante conocer cuáles son los aspectos específicos que generan satisfacción o insatisfacción y cuáles son los principales temas que se repiten entre los consumidores.

En este contexto, el presente proyecto propone el desarrollo de una aplicación basada en técnicas de Procesamiento del Lenguaje Natural que permita analizar automáticamente reseñas de productos escritas en español. La solución integra clasificación de sentimientos, detección de aspectos y modelado de temas en una única herramienta interactiva, facilitando el análisis de la voz del cliente y proporcionando información útil para empresas de comercio electrónico, fabricantes, equipos de atención al cliente y responsables de marketing interesados en comprender mejor la percepción de sus consumidores.

3. Objetivos

3.1. Objetivo general

Desarrollar una aplicación de Procesamiento del Lenguaje Natural capaz de analizar automáticamente reseñas de productos escritas en español, identificando el sentimiento expresado por el usuario, los aspectos mencionados y el tema predominante de cada opinión.

3.2. Objetivos específicos

- Explorar y analizar el conjunto de datos con el fin de comprender su estructura, calidad y distribución.

- Implementar un proceso de preprocesamiento del lenguaje natural que permita limpiar, normalizar y transformar las reseñas en un formato adecuado para su análisis.
- Evaluar diferentes técnicas de representación textual con el propósito de analizar sus características y seleccionar las representaciones más adecuadas para los modelos de clasificación de sentimientos y el análisis semántico de las reseñas.
- Aplicar modelado de temas mediante Latent Dirichlet Allocation (LDA) para descubrir automáticamente los principales temas presentes en las opiniones de los clientes, facilitando la interpretación del contenido más allá de la clasificación del sentimiento.
- Desarrollar y comparar un modelo clásico basado en Naive Bayes y un modelo neuronal basado en Long Short-Term Memory (LSTM) para la clasificación automática de sentimientos, evaluando su desempeño mediante métricas de exactitud, precisión, recall y F1-score.
- Implementar un mecanismo de detección de aspectos que permita identificar automáticamente características relevantes mencionadas en las reseñas.
- Diseñar e implementar una interfaz interactiva utilizando Gradio, que integre todos los componentes desarrollados y permita analizar nuevas reseñas en tiempo real, mostrando al usuario el sentimiento detectado, las probabilidades de clasificación, el tema principal identificado y los aspectos encontrados en el texto.

4. Descripción del dataset

Para el desarrollo del proyecto se utilizó el conjunto de datos *KRadim/edit_amazon_reviews_multi_es*, disponible en la plataforma Hugging Face. Este dataset contiene aproximadamente 210.000 reseñas de productos escritas en español e incluye variables como el texto completo de la reseña, el título, la categoría del producto, el idioma y la calificación otorgada por el usuario mediante estrellas.

Durante la etapa de exploración de datos se verificó que el conjunto no presentaba valores faltantes en las variables utilizadas para el análisis y que la distribución de las calificaciones era prácticamente uniforme entre una y cinco estrellas. Asimismo, se identificó un número reducido de reseñas duplicadas, las cuales representaban una

proporción mínima respecto al total de registros y no afectaban significativamente el entrenamiento de los modelos.


Con el propósito de realizar un problema de clasificación multiclase, las calificaciones fueron transformadas en tres categorías de sentimiento: las reseñas con una y dos estrellas se etiquetaron como negativas, las de tres estrellas como neutras y las de cuatro y cinco estrellas como positivas. Esta transformación permitió obtener un conjunto de datos balanceado y adecuado para el entrenamiento y evaluación de los modelos de clasificación.

5. Metodología y desarrollo

El desarrollo del proyecto siguió un pipeline estructurado de Procesamiento del Lenguaje Natural. En primer lugar, se realizó una exploración del conjunto de datos para analizar su estructura, distribución y calidad. Posteriormente, se implementó un proceso de limpieza y normalización del texto que incluyó conversión a minúsculas, eliminación de caracteres especiales, signos de puntuación, números y palabras vacías, conservando términos relevantes para el análisis del sentimiento.

Como siguiente etapa se aplicaron distintas técnicas de representación textual. Se implementó Bag of Words como representación básica del texto, TF-IDF para el entrenamiento del modelo clásico Naive Bayes y Word2Vec para ilustrar el uso de embeddings distribucionales. Paralelamente, la red LSTM empleó secuencias generadas mediante Tokenizer y una capa Embedding entrenada automáticamente durante el proceso de aprendizaje.

Finalmente, se desarrollaron los modelos de análisis utilizando LDA para el descubrimiento automático de temas, Naive Bayes para la clasificación clásica y una red neuronal LSTM para la clasificación basada en aprendizaje profundo. Todos estos componentes fueron integrados en una interfaz desarrollada con Gradio, permitiendo analizar nuevas reseñas y presentar los resultados de forma visual e interactiva.




6. Resultados

El análisis exploratorio confirmó que el conjunto de datos presentaba una distribución equilibrada de las clases y una adecuada calidad para el entrenamiento de modelos de aprendizaje automático. Asimismo, el proceso de preprocesamiento permitió reducir el ruido presente en las reseñas y generar representaciones textuales apropiadas para las distintas técnicas implementadas durante el proyecto.

En cuanto a la clasificación de sentimientos, el modelo Naive Bayes obtuvo una exactitud de **68,53 %** y un valor **F1 Macro de 68,64 %**, mientras que la red neuronal LSTM alcanzó una exactitud de **69,43 %** y un **F1 Macro de 69,24 %**. Aunque ambos modelos presentaron resultados similares, la LSTM mostró un desempeño ligeramente superior, evidenciando una mejor capacidad para capturar el contexto de las palabras.

Por otra parte, el modelo LDA permitió identificar seis temas principales relacionados con funcionamiento, envío, calidad-precio, diseño, accesorios y facilidad de uso. Finalmente, la interfaz desarrollada con Gradio permitió integrar el análisis de sentimientos, el modelado de temas y la detección de aspectos en una aplicación funcional, validada mediante pruebas con reseñas positivas, neutras y negativas.

modelo	accuracy	precision_macro	recall_macro	f1_macro
LSTM	0,694	0,691	0,694	0,692
Naive Bayes	0,685	0,688	0,685	0,686



7. Conclusiones y recomendaciones

El proyecto permitió desarrollar una solución completa para el análisis de la voz del cliente utilizando diferentes técnicas de Procesamiento del Lenguaje Natural. La combinación de modelos clásicos y redes neuronales permitió comparar distintos enfoques de clasificación, mientras que el modelado de temas y la detección de aspectos complementaron la interpretación de las opiniones expresadas por los usuarios.

Los resultados obtenidos muestran que la red LSTM alcanzó el mejor desempeño general, aunque la diferencia respecto a Naive Bayes fue relativamente pequeña. Esto demuestra que los modelos clásicos continúan siendo una alternativa competitiva cuando se dispone de representaciones adecuadas como TF-IDF, mientras que las redes neuronales ofrecen una mejor capacidad para comprender el contexto del lenguaje.

Como trabajo futuro, se recomienda evaluar modelos basados en Transformers para español, como BETO, comparar el rendimiento con arquitecturas GRU, incorporar técnicas supervisadas para la detección de aspectos y desplegar la aplicación en una plataforma en la nube para facilitar su utilización en escenarios reales.

8. Bibliografía

Hugging Face. (2025). KRadim/edit_amazon_reviews_multi_es. https://huggingface.co/datasets/KRadim/edit_amazon_reviews_multi_es

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993–1022. <http://www.jmlr.org/papers/v3/blei03a.html>

Chollet, F. (2023). *Deep Learning with Python* (2nd ed.). Manning Publications.

Gensim Development Team. (2024). Gensim: Topic modelling for humans. <https://radimrehurek.com/gensim/>

Jurafsky, D., & Martin, J. H. (2025). *Speech and Language Processing* (3rd ed., draft). <https://web.stanford.edu/~jurafsky/slp3/>

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. <https://nlp.stanford.edu/IR-book/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.csail.mit.edu/papers/v12/pedregosa11a.html>

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. <https://doi.org/10.18653/v1/D19-1410>

TensorFlow Developers. (2025). TensorFlow documentation. <https://www.tensorflow.org/>

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3), 261–272. <https://doi.org/10.1038/s41592-019-0686-2>